	Colegio Universitario de Cartago	
	BIG DATA (BD)	

I Cuatrimestre 2026
BD-143 Programación II
Profesor Osvaldo González Chaves
Proyecto II

Descripción del proyecto

Desarrollar un sistema, en Python y con Programación Orientada a Objetos, que ingeste datos de películas desde archivos CSV, que permita consultas, análisis exploratorio (EDA) y visualización de gráficos o de manera interactiva mediante un dashboard.

Objetivos

- **Ingesta**: Cargar archivos CSV con películas de TMDB (The Movie Database) 2020-2025.
- **EDA**: Proveer métodos OO y un notebook con análisis descriptivo.
- **Visualización**: Crear gráficas clave (que cuenten una historia) y/o un dashboard (Streamlit) para comunicar hallazgos.

Rubros de calificación

Criterio	Porcentaje
Programación Orientada a Objetos (POO)	50%
Análisis exploratorio de datos (EDA)	20%
Visualización de datos (gráficos, tendencias, comparaciones etc)	20%
Uso de repositorio GitHub	10%
Puntos extra: *Dashboard interactivo (ej. con Streamlit)*	*2%*

Total: 100%

Requerimientos funcionales del proyecto TMDB Movie Insights.

1. Carga de datos: La clase CargadorDatos debe ser capaz de cargar el dataset " tmdb_2020_to_2025.csv" con sus métodos. Pueden usar los atributos que sean necesarios. Registrar número de filas y porcentaje de nulos al cargar.

2. Procesamiento EDA. La clase ProcesadorEDA debe generar al menos:

- **Limpieza de datos (limpieza_datos)**: Manejo de nulos (imputación/eliminación justificada), tipos correctos (numéricos/fechas/categóricos) y normalización de categorías (géneros/idiomas)
- **Resumen descriptivo (resumen_descriptivo)**: Medidas (count, mean, std, min, q1, median, q3, max) para variables numéricas.
- **Matriz de correlación (matriz_correlacion)**
- Puede crear más métodos que considere (outliers, análisis de rentabilidad, etc.)

3. **Visualización estática e interactiva**: La clase Visualizador creará: Histogramas, scatter, heatmap, etc. con Matplotlib / Plotly
   Cada visualización debe contar una historia, sea creativo y analítico; obtenga estadísticas interesantes en los datos.

   Narrativa: cada gráfico debe incluir título claro, texto/insight (una "mini historia")

Estructura de carpetas del proyecto en pycharm, utilice el .zip “Movie_Insights” y cree las carpetas y archivos necesarios según el siguiente esquema:

```
Movie_Insights/
├── src/                    # Código fuente principal
│   ├── eda/                # Exploración de datos y estadísticas descriptivas (Clase ProcesadorEDA)
│   ├── visualizacion/      # Visualización de datos y mapas (Clase Visualizador)
│   ├── helpers/            # Funciones auxiliares reutilizables (Clase Utilidades)
│   └── main.py             # Punto de entrada del proyecto
│
├── notebooks/              # Jupyter notebooks para desarrollo y presentación
│ ├─ 01_EDA.ipynb
│ └─ 02_Visualizacion.ipynb
│
├── data/                   # Archivos
    └── raw                 # Archivos CSV (En crudo)
│   └── processed/          # Archivos CSV limpio (tmdb_movies_clean.csv)
│
├─ dashboard/               # Streamlit(opcional)
│ ├─ app.py                 # punto de entrada: `streamlit run dashboard/app.py`
│
└─ README.md    # Documente el proyecto en un markdown
```

Cada módulo debe implementarse usando clases que representen entidades o procesos:

• **cargaDatos**/ → Clase CargadorDatos: cargar el dataset de la carpeta "data/raw/tmdb_2020_to_2025.csv"

• **eda**/ → Clase ProcesadorEDA:

- Limpiar el dataset y crear el archivo tmdb_movies_clean.csv (se guarda en la carpetadata/processed/tmdb_movies_clean.csv)
- Realizar análisis estadístico
- Matriz de correlación
- Exploración inicial de los datos

• **visualizacion**/ → Clase Visualizador: crea gráficos (líneas, barras, heatmaps, etc.). Sea creativo, cada gráfico debe contar una historia.

• **helpers**/ → Clase Utilidades: contiene funciones auxiliares reutilizables para validaciones, formateo, etc. (opcional)

• **notebooks**/ → notebooks de Python que contiene:

– **Notebook 01_EDA.ipynb**: invoca la clase CargadorDatos y ProcesadorEDA

– **Notebook 02_Visualizacion.ipynb**: invoca la clase Visualizador

Puntos extra:

Como complemento, se propone generar dashboard interactivo en una plataforma gratuita como Streamlit, para visualizar resultados del análisis exploratorio de manera sencilla y atractiva.

Entregables

1. Repositorio Git con código.

Indicaciones

1. Realizarlo en parejas.
2. Fecha de entrega: miércoles 24/03/2026 a las 6 pm.
3. Debe correr todo en el momento de la revisión, asegúrese que este listo cuando el profesor lo llame a revisión. No habrá ampliación de tiempo para ajustes en el código.
4. Debe estar el código en el repositorio antes de la revisión